

# Régression logistique

## [Logistic regression]

Titouan Vayer, Laetitia Chapel



STID 2

2019 – 2020

# Sommaire

Introduction : la classification supervisée binaire

Objectifs du cours

Le modèle de régression logistique

Estimation des paramètres du modèle

Odds et odds-ratio

Evaluation et sélection du “meilleur” modèle

# Sommaire

Introduction : la classification supervisée binaire

Objectifs du cours

Le modèle de régression logistique

Estimation des paramètres du modèle

Odds et odds-ratio

Evaluation et sélection du “meilleur” modèle

# Introduction : la classification supervisée binaire


## Organisation du cours

- 2 CMs
- 6 TDs : papier & ordinateur
- Evaluation sur table papier crayon 1h30 avec anti-sèche autorisé

# Introduction : la classification supervisée binaire

## Objectif de la classification supervisée binaire


Apprendre à un ordinateur à **classer** selon **deux catégories** des individus  $x$  en fonction de leurs **données descriptives**  $(x_1, \dots, x_p)$



# Introduction : la classification supervisée binaire

## Objectif de la classification supervisée binaire

Apprendre à un ordinateur à **classer** selon **deux catégories** des individus  $x$  en fonction de leurs **données descriptives**  $(x_1, \dots, x_p)$



Par exemple :

- Donner un crédit en fonction de données d'un individu (âge, csp, ...)
- Détecter une maladie en fonction de données d'une image
- Proposer un médicament adapté en fonction des données médicales d'un individu
- Détecter un obstacle pour la voiture autonome
- Trier des CVs

## Comment apprendre $f$ ?


- Généralement on dispose d'un ensemble de plusieurs individus ("un dataset"), de leurs données descriptives et de leur catégorie respective ("la classe de l'individu")
- On essaye d'apprendre une "règle" de classification qui sépare nos données selon les deux catégories
- La règle est une fonction  $f$  qui s'appelle un classifieur

# Introduction : la classification supervisée binaire


## Comment apprendre $f$ ?

- Généralement on dispose d'un ensemble de plusieurs individus ("un dataset"), de leurs données descriptives et de leur catégorie respective ("la classe de l'individu")
- On essaye d'apprendre une "règle" de classification qui sépare nos données selon les deux catégories
- La règle est une fonction  $f$  qui s'appelle un classifieur

Examples



Positions in 2D





# Introduction : la classification supervisée binaire

## Comment apprendre $f$ ?

- Généralement on dispose d'un ensemble de plusieurs individus ("un dataset"), de leurs données descriptives et de leur catégorie respective ("la classe de l'individu")
- On essaye d'apprendre une "règle" de classification qui sépare nos données selon les deux catégories
- La règle est une fonction  $f$  qui s'appelle un classifieur

Examples



Labels

Class 1  $\times$


Class 2  $\circ$

Class 1  $\times$

Class 2  $\circ$

Class 1  $\times$

Positions in 2D



# Introduction : la classification supervisée binaire

## Comment apprendre $f$ ?

- Généralement on dispose d'un ensemble de plusieurs individus ("un dataset"), de leurs données descriptives et de leur catégorie respective ("la classe de l'individu")
- On essaye d'apprendre une "règle" de classification qui sépare nos données selon les deux catégories
- La règle est une fonction  $f$  qui s'appelle un classifieur

Examples



Labels

Class 1  $\times$

Class 2  $\circ$

Class 1  $\times$


Class 2  $\circ$

Class 1  $\times$



Classifier

Positions in 2D




# Introduction : la classification supervisée binaire


## Comment apprendre $f$ ?

- Généralement on dispose d'un ensemble de plusieurs individus ("un dataset"), de leurs données descriptives et de leur catégorie respective ("la classe de l'individu")
- On essaye d'apprendre une "règle" de classification qui sépare nos données selon les deux catégories
- La règle est une fonction  $f$  qui s'appelle un classifieur

Amazon



Ground truth



US\_OT3

## La classification supervisée binaire

L'objectif de la classification supervisée binaire est :

- Apprendre à un ordinateur (avec un algorithme codé dans un langage informatique comme R)
- A trouver une règle de classification ( $f$ )
- En fonction de données d'individus ( $x$  et leur classe)
- De sorte que la règle de décision satisfasse un certain critère (qu'elle classifie au mieux tous nos points)

# Introduction : la classification supervisée binaire

- **Entrée** : un ensemble de  $N$  points décrits par  $p$  attributs, où  $\{\mathbf{x}_i\}_{i=1\dots p}$  contient les valeurs prises par la  $i^{\text{ème}}$  variable pour l'ensemble des individus

$$\mathbf{x}_i = \begin{bmatrix} x_i^1 \\ x_i^2 \\ \dots \\ x_i^N \end{bmatrix} \text{ et on note } \mathbf{x}^n \text{ les attributs du } n^{\text{ème}} \text{ individu}$$
$$\mathbf{x}^n = [x_1^n, x_2^n, \dots, x_p^n]$$

- Des classes  $\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_N \end{bmatrix} \in \mathcal{Y}$ , avec  $y_n$  la classe du  $n^{\text{ème}}$  individu

# Introduction : la classification supervisée binaire

- **Entrée** : un ensemble de  $N$  points décrits par  $p$  attributs, où  $\{\mathbf{x}_i\}_{i=1\dots p}$  contient les valeurs prises par la  $i^{\text{ème}}$  variable pour l'ensemble des individus

$$\mathbf{x}_i = \begin{bmatrix} x_i^1 \\ x_i^2 \\ \dots \\ x_i^N \end{bmatrix} \text{ et on note } \mathbf{x}^n \text{ les attributs du } n^{\text{ème}} \text{ individu}$$
$$\mathbf{x}^n = [x_1^n, x_2^n, \dots, x_p^n]$$

- Des classes  $\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_N \end{bmatrix} \in \mathcal{Y}$ , avec  $y_n$  la classe du  $n^{\text{ème}}$  individu

- **Apprentissage supervisé** : la sortie désirée est connue  
But : trouver une fonction  $f$  telle que

$$f([\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p]) + \epsilon = \mathbf{y}$$

- si  $\mathcal{Y} = \mathbb{R}$  : problème de régression
- si  $\mathcal{Y} \in \mathcal{S}$ , avec  $\mathcal{S}$  un ensemble fini : problème de classification
- si  $\mathcal{S} = \{0, 1\}$  contient 2 éléments : classification binaire

# Sommaire

Introduction : la classification supervisée binaire

## Objectifs du cours

Le modèle de régression logistique

Estimation des paramètres du modèle

Odds et odds-ratio

Evaluation et sélection du “meilleur” modèle

# Objectifs du cours

- Comprendre le principe de la régression logistique
- Etre capable de mettre en oeuvre une régression logistique avec R
- Savoir construire un modèle de régression logistique
- Etre capable d'interpréter les résultats d'une régression logistique



# Sommaire

Introduction : la classification supervisée binaire

Objectifs du cours

Le modèle de régression logistique

- Le modèle de régression linéaire

- Régression logistique

- Le modèle

- Les variables explicatives

- Hypothèse de linéarité du logit

Estimation des paramètres du modèle

Odds et odds-ratio

Evaluation et sélection du "meilleur" modèle

# Le modèle de régression logistique

## Le modèle de régression linéaire

$$\mathbf{y} = f(\mathbf{X}) + \epsilon = \beta_0 + \beta_1 \mathbf{x}_1 + \cdots + \beta_p \mathbf{x}_p + \epsilon$$

et pour une observation  $n$  :


$$y_n = \beta_0 + \beta_1 x_1^n + \cdots + \beta_p x_p^n + \epsilon_n \in \mathbb{R}$$

- Estimations  $b_0, b_1, \dots, b_p$  des coefficients du modèle  $\beta_0, \beta_1, \dots, \beta_p$  par la méthode des MC
- Test sur les coefficients
- Mesure de qualité du modèle

# Le modèle de régression logistique

## Régression logistique


- Modéliser  $y \in \{0, 1\}$



# Le modèle de régression logistique

## Régression logistique

- Modéliser  $y \in \{0, 1\}$



- Le modèle linéaire ne convient pas !

# Le modèle de régression logistique


## Régression logistique

- Dans le cadre de la régression logistique on cherche à modéliser les probabilités :

$$\pi(\mathbf{x}^n) = \mathbb{P}(y_n = 1 \mid \mathbf{x}^n) \text{ ou } 1 - \pi(\mathbf{x}^n) = \mathbb{P}(y_n = 0 \mid \mathbf{x}^n)$$

et pour l'ensemble des individus

$$\pi(\mathbf{X}) = \mathbb{P}(y = 1 \mid \mathbf{X}) \text{ ou } 1 - \pi(\mathbf{X}) = \mathbb{P}(y = 0 \mid \mathbf{X})$$



- Une fois qu'on connaît la probabilité qu'a un individu d'appartenir à une classe il est facile de deviner à quelle classe il appartient.

# Le modèle de régression logistique


## Régression logistique

Comment modéliser  $\pi(x^n)$  ?

- La régression logistique est basée sur la fonction logistique

$$f(z) = \frac{\exp(z)}{1 + \exp(z)} = \frac{1}{1 + \exp(-z)}$$

avec  $f(z) \in [0, 1]$  et  $z \in \mathbb{R}$



# Le modèle de régression logistique

## Le modèle

- Le modèle de régression logistique s'écrit :

$$\pi(\mathbf{X}) = \frac{\exp(\beta_0 + \beta_1 \mathbf{x}_1 + \cdots + \beta_p \mathbf{x}_p)}{1 + \exp(\beta_0 + \beta_1 \mathbf{x}_1 + \cdots + \beta_p \mathbf{x}_p)}$$

avec  $\pi(\mathbf{x}^n) \in [0, 1]$  et  $\beta_0 + \beta_1 x_1^n + \cdots + \beta_p x_p^n \in \mathbb{R}$

- ou de façon équivalente :

$$\text{logit}(\pi(\mathbf{X})) = \log\left(\frac{\pi(\mathbf{X})}{1 - \pi(\mathbf{X})}\right) = \beta_0 + \beta_1 \mathbf{x}_1 + \cdots + \beta_p \mathbf{x}_p$$

# Le modèle de régression logistique

## Le modèle

- Le modèle de régression logistique s'écrit :

$$\pi(\mathbf{X}) = \frac{\exp(\beta_0 + \beta_1 \mathbf{x}_1 + \cdots + \beta_p \mathbf{x}_p)}{1 + \exp(\beta_0 + \beta_1 \mathbf{x}_1 + \cdots + \beta_p \mathbf{x}_p)}$$

avec  $\pi(\mathbf{x}^n) \in [0, 1]$  et  $\beta_0 + \beta_1 x_1^n + \cdots + \beta_p x_p^n \in \mathbb{R}$

- ou de façon équivalente :

$$\text{logit}(\pi(\mathbf{X})) = \log\left(\frac{\pi(\mathbf{X})}{1 - \pi(\mathbf{X})}\right) = \beta_0 + \beta_1 \mathbf{x}_1 + \cdots + \beta_p \mathbf{x}_p$$

- avec  $\mathbf{x}_i$  variables quantitatives ou binaires représentant les données des individus.



# Le modèle de régression logistique

## Les variables explicatives

- **Variable explicative qualitative à 2 modalités** : les modalités sont recodées  $x_i^n \in \{0, 1\}$ , la modalité 0 étant appelée *modalité de référence*.
- **Variable explicative qualitative à  $m > 2$  modalités** : on crée  $m - 1$  *variables design* (indicatrices associées à chaque modalité).
- **Variable explicative quantitative** : on vérifie l'hypothèse de *linéarité du logit*.

# Le modèle de régression logistique

## Hypothèse de linéarité du logit

- Lorsqu'une variable passe de la valeur  $x_1$  à  $x_1 + 1$ , la valeur  $\text{logit}(\pi(x))$  augmente de  $\beta_1$ , quelle que soit la valeur de  $x_1 \Rightarrow$  le logit est linéaire.
- On doit vérifier cette hypothèse pour pouvoir intégrer une variable quantitative dans le modèle, et la mettre en classe sinon.
- Pour vérifier l'hypothèse, on peut notamment mettre la variable en classe, puis tracer l'évolution en fonction du logit.

# Sommaire

Introduction : la classification supervisée binaire

Objectifs du cours

Le modèle de régression logistique

**Estimation des paramètres du modèle**

Test du rapport de vraisemblance : test de significativité globale du modèle

Test de Wald : test de significativité individuelle des variables

Odds et odds-ratio

Evaluation et sélection du “meilleur” modèle

# Estimation des paramètres du modèle

## Comment trouver les paramètres $\beta_0, \dots, \beta_p$ ?

L'objectif est de trouver  $\beta_0, \dots, \beta_p$  de sorte que notre modèle "colle" le mieux à nos données.

## Comment trouver les paramètres $\beta_0, \dots, \beta_p$ ?

L'objectif est de trouver  $\beta_0, \dots, \beta_p$  de sorte que notre modèle "colle" le mieux à nos données.

- On ne peut pas utiliser la méthode des moindres carrés (on ne modélise pas directement  $y_n$ ) : lorsque  $y_n \in \mathbb{R}$ , on peut écrire

$$\min \sum_{n=1}^N e_n^2 = \min \sum_{n=1}^N (y_n - \hat{y}_n)^2 = \min \sum_{n=1}^N (y_n - (\beta_0 + \beta_1 x_1^n + \dots + \beta_p x_p^n))^2$$

- On utilise la méthode du maximum de vraisemblance

$$\max \prod_{n=1}^N \pi(x^n)^{y_n} \times (1 - \pi(x^n))^{1-y_n}$$

# Estimation des paramètres du modèle

## Comment trouver les paramètres $\beta_0, \dots, \beta_p$ ?

L'objectif est de trouver  $\beta_0, \dots, \beta_p$  de sorte que notre modèle "colle" le mieux à nos données.

- On ne peut pas utiliser la méthode des moindres carrés (on ne modélise pas directement  $y_n$ ) : lorsque  $y_n \in \mathbb{R}$ , on peut écrire

$$\min \sum_{n=1}^N e_n^2 = \min \sum_{n=1}^N (y_n - \hat{y}_n)^2 = \min \sum_{n=1}^N (y_n - (\beta_0 + \beta_1 x_1^n + \dots + \beta_p x_p^n))^2$$

- On utilise la méthode du maximum de vraisemblance

$$\max \prod_{n=1}^N \pi(x^n)^{y_n} \times (1 - \pi(x^n))^{1-y_n}$$

- si  $y_n = 1$ , on veut que  $\pi(x^n)$  soit proche de 1  $\Rightarrow \pi(x^n)^{y_n}$  proche de 1 et  $(1 - \pi(x^n))^{1-y_n} = 1$
- si  $y_n = 0$ , on veut que  $\pi(x^n)$  soit proche de 0  $\Rightarrow \pi(x^n)^{y_n} = 1$  et  $(1 - \pi(x^n))^{1-y_n}$  proche de 1

## Estimation des paramètres du modèle

- On cherche donc des estimations  $b_0, b_1, \dots, b_p$  des paramètres inconnus  $\beta_0, \beta_1, \dots, \beta_p$  telles que la vraisemblance  $\mathcal{L}$  soit maximum :

$$\max \mathcal{L} = \max \prod_{n=1}^N \pi(x^n)^{y_n} \times (1 - \pi(x^n))^{1-y_n}$$

avec

$$\pi(x^n) = \frac{\exp(\beta_0 + \beta_1 x_1^n + \dots + \beta_p x_p^n)}{1 + \exp(\beta_0 + \beta_1 x_1^n + \dots + \beta_p x_p^n)}$$

- ce qui est équivalent à minimiser la déviance  $-2 \times \log(\mathcal{L})$

$$\min -2 \times \log(\mathcal{L})$$

## Estimation des paramètres du modèle

- On cherche donc des estimations  $b_0, b_1, \dots, b_p$  des paramètres inconnus  $\beta_0, \beta_1, \dots, \beta_p$  telles que la vraisemblance  $\mathcal{L}$  soit maximum :

$$\max \mathcal{L} = \max \prod_{n=1}^N \pi(x^n)^{y_n} \times (1 - \pi(x^n))^{1-y_n}$$

avec

$$\pi(x^n) = \frac{\exp(\beta_0 + \beta_1 x_1^n + \dots + \beta_p x_p^n)}{1 + \exp(\beta_0 + \beta_1 x_1^n + \dots + \beta_p x_p^n)}$$

- ce qui est équivalent à minimiser la déviance  $-2 \times \log(\mathcal{L})$

$$\min -2 \times \log(\mathcal{L})$$

- On utilise des méthodes d'optimisation pour résoudre le problème



## Estimation des paramètres du modèle

- On cherche donc des estimations  $b_0, b_1, \dots, b_p$  des paramètres inconnus  $\beta_0, \beta_1, \dots, \beta_p$  telles que la vraisemblance  $\mathcal{L}$  soit maximum :

$$\max \mathcal{L} = \max \prod_{n=1}^N \pi(x^n)^{y_n} \times (1 - \pi(x^n))^{1-y_n}$$

avec

$$\pi(x^n) = \frac{\exp(\beta_0 + \beta_1 x_1^n + \dots + \beta_p x_p^n)}{1 + \exp(\beta_0 + \beta_1 x_1^n + \dots + \beta_p x_p^n)}$$

- ce qui est équivalent à minimiser la déviance  $-2 \times \log(\mathcal{L})$

$$\min -2 \times \log(\mathcal{L})$$

- On utilise des méthodes d'optimisation pour résoudre le problème
- Note* : pour  $N$  fixé, le modèle 1 sera meilleur que le modèle 2 si  $\mathcal{L}_1 > \mathcal{L}_2$

## Estimation des paramètres du modèle

### Test du rapport de vraisemblance : test de significativité globale du modèle

- On cherche à savoir si il y a un “lien” entre au moins une variable explicative  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$  et la variable à expliquer  $Y$

$$\mathcal{H}_0 : \beta_1 = \dots = \beta_p = 0$$

$$\mathcal{H}_1 : \exists i \text{ tel que } \beta_i \neq 0$$

## Estimation des paramètres du modèle

### Test du rapport de vraisemblance : test de significativité globale du modèle

- On cherche à savoir si il y a un “lien” entre au moins une variable explicative  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$  et la variable à expliquer  $Y$

$$\mathcal{H}_0 : \beta_1 = \dots = \beta_p = 0$$

$$\mathcal{H}_1 : \exists i \text{ tel que } \beta_i \neq 0$$

- Sous  $\mathcal{H}_0$ ,

$$D = -2 \log \left( \frac{\mathcal{L}_0}{\mathcal{L}_p} \right) \sim \chi_p^2$$

# Estimation des paramètres du modèle

## Test de Wald : test de significativité individuelle des variables

- On teste la significativité individuelle d'une variable  $\mathbf{x}_i$

$$\mathcal{H}_0 : \beta_i = 0$$

$$\mathcal{H}_1 : \beta_i \neq 0$$

# Estimation des paramètres du modèle

## Test de Wald : test de significativité individuelle des variables

- On teste la significativité individuelle d'une variable  $\mathbf{x}_i$

$$\mathcal{H}_0 : \beta_i = 0$$

$$\mathcal{H}_1 : \beta_i \neq 0$$

- Sous  $\mathcal{H}_0$ ,

$$W^2 = \left( \frac{b_i^2}{\hat{V}\hat{A}R(b_i)} \right) \sim \chi_1^2$$

where  $\hat{V}\hat{A}R(b_i)$  is an estimation of the variance of  $b_i$

# Sommaire

Introduction : la classification supervisée binaire

Objectifs du cours

Le modèle de régression logistique

Estimation des paramètres du modèle

**Odds et odds-ratio**

Evaluation et sélection du “meilleur” modèle

## odds

- La régression logistique est basée sur l'estimation d'un **odds** ou **cote**

$$\text{odds} = \frac{\mathbb{P}(y_n = 1 \mid \mathbf{x}^n)}{\mathbb{P}(y_n = 0 \mid \mathbf{x}^n)} = \frac{\pi(\mathbf{x}^n)}{1 - \pi(\mathbf{x}^n)}$$

## Exemple

En Bretagne, il y a 25% de chances de pleuvoir demain. En Irlande, il y a 75 % de chances de pleuvoir demain.  
odds(Bretagne) ? odds(Irlande) ?

## Interprétation de $b_0$

- Soit un modèle qui ne contient que l'intercept (pas de variable explicative)

$$\text{logit}(\pi(\mathbf{x}^n)) = \beta_0$$

- Une estimation  $b_0$  du paramètre inconnu  $\beta_0$  correspond au logarithme de l'odds

$$b_0 = \log \frac{\pi(\mathbf{x}^n)}{1 - \pi(\mathbf{x}^n)}$$

et on a donc

$$\exp(b_0) = \frac{\pi(\mathbf{x}^n)}{1 - \pi(\mathbf{x}^n)}$$

- $\exp(b_0)$  correspond donc au nombre de fois de chances de plus que l'on a d'observer  $y = 1$  par rapport à  $y = 0$ .



# Odds et odds-ratio

Odds-ratio : cas d'une variable explicative binaire  $x \in \{0, 1\}$

- Odds-ratio : rapport entre 2 odds
- Soit une variable  $x$  qui prend 2 modalités : 0 ou 1

$$OR(x) = \frac{\pi(1)}{1 - \pi(1)} / \frac{\pi(0)}{1 - \pi(0)}$$

- Indique ainsi quelle est la quantité de chance en plus d'être  $y = 1$  dans le groupe  $x = 1$  par rapport au groupe  $x = 0$ .

## Exemple

En Bretagne, il y a 25% de chances de pleuvoir demain. En Irlande, il y a 75 % de chances de pleuvoir demain.  
odds-ratio(Irlande vs Bretagne) ?

# Odds et odds-ratio

Odds-ratio : cas d'une variable explicative binaire  $x \in \{0, 1\}$

- Dans ce cas, on a (preuve...)

$$OR(x) = \exp(\beta_1)$$

- Vocabulaire :
  - si  $OR > 1$  : facteur de risque
  - si  $OR < 1$  : facteur de protection
- On peut également calculer des IC autour des OR

Odds-ratio : cas d'une variable explicative continue  $x \in \mathbb{R}$

- Dans ce cas, on a (preuve...)

$$OR(x) = \exp(\beta_1)$$

qui correspond à l'évolution de la chance d'être  $y = 1$  lorsque la variable  $x$  augmente de 1 unité (passe de la valeur  $a$  à la valeur  $a + 1$ )

- Attention à l'hypothèse de linéarité du logit !

# Sommaire

Introduction : la classification supervisée binaire

Objectifs du cours

Le modèle de régression logistique

Estimation des paramètres du modèle

Odds et odds-ratio

Evaluation et sélection du “meilleur” modèle

# Evaluation et sélection du “meilleur” modèle

- Approche traditionnelle : chercher le modèle le plus parsimonieux qui explique au mieux les données
- Idée générale : on cherche le modèle qui maximise la vraisemblance. MAIS, la vraisemblance augmente avec la complexité du modèle : on cherche donc un compromis entre la qualité de l'ajustement et la complexité du modèle.
- 2 critères classiques :

- Critère d'Akaike

$$AIC = -2\mathcal{L} + 2p$$

- Critère Bayes Information Criterion

$$BIC = -2\mathcal{L} + p \log(N)$$

# Evaluation et sélection du “meilleur” modèle

## Méthodes de sélection

- Il est coûteux voire impossible de tester tous les modèles et choisir celui qui minimise le critère BIC ou AIC : on préfère des méthodes pas à pas
- Méthode ascendante : on ajoute à chaque itération une variable dans le modèle – forward
- Méthode descendante : on supprime à chaque itération une variable du modèle – backward
- Méthode stepwise

# Evaluation et sélection du “meilleur” modèle

## Evaluation d'un modèle

- On peut également comparer des modèles en fonction de leur performance en prédiction
- parcours école : cf module introduction à l'apprentissage automatique (calcul de l'estimation du risque réel, de l'aire sous la courbe ROC, TVP, TVN)
- parcours STID : cf module classification